

УНИВЕРЗИТЕТ У БЕОГРАДУ
ЕЛЕКТРОТЕХНИЧКИ ФАКУЛТЕТ



**КЛАСИФИКАЦИЈА ПОЛИТИЧКИХ СТАВОВА У
КОМЕНТАРИМА НА ДРУШТВЕНИМ МРЕЖАМА О
СТУДЕНТСКИМ ПРОТЕСТИМА У СРБИЈИ**

Предмет: Обрада природних језика

Студенти:

Наталија Богдановић 2025/3382

Никола Бабић 2025/3398

Марија Јевтић 2025/3202

Ана Булатовић 2025/3046

Београд, Август 2026.

Садржај

1. Приказ проблема и теме	3
1.1. Категорије политичких ставова у скупу података.....	3
1.2. Циљ пројекта	4
2. Прикупљање података	5
2.1. Прикупљање сирових података са друштвених мрежа.....	5
2.2. Чишћење и стандардизација корпуса.....	6
2.2.1. Припрема сировог корпуса	6
2.2.2. Анотациони скуп.....	6
2.2.3. Претпроцесирање за <i>baseline</i> моделе	7
2.2.4. Енкодерски модели	7
2.3. Анотација коментара	7
2.4.3. Најчешће речи — семантички отисак класа.....	11
3. Обучавање и евалуација модела	13
3.1. <i>Baseline</i> модели	13
3.1.1. Претпроцесирање и репрезентација текста.....	13
3.1.2. Евалуација	14
3.1.3. Резултати.....	14
3.1.4. Дискусија	19
3.2. Енкодер	20
3.2.1. Модели	20
3.2.2. Поставка и хиперпараметри.....	21
3.2.3. Резултати.....	22
3.2.4. Дискусија	28
4. Закључак	29

1. Приказ проблема и теме

Предмет овог пројекта је класификација политичких ставова у коментарима на друштвеним мрежама који се односе на студентске протесте у Србији. Овај задатак припада области обраде природних језика, тачније задатку анализе сентимента и класификације текста, чији је циљ аутоматско одређивање политичке оријентације и става аутора коментара на основу самог текста.

Проблем је формулисан као задатак трокласне класификације текста: улаз представља један коментар са друштвене мреже, док је излаз категорија политичког става коју коментар изражава. Пошто се став аутора не наводи експлицитно, модел мора да препозна карактеристичне језичке обрасце као што су избор речи, тон, употреба емотивне лексике, реторички уређаји, као и целокупна семантичка структура коментара.

За тематски домен одабрани су коментари са друштвених мрежа поводом студентских протеста у Србији, који су се догодили у периоду 2024-2026. године. Ова тема је изабрана због високог степена поларизације у јавном дискурсу, што омогућава јасно разликовање различитих политичких ставова. Са друге стране, коментари на друштвеним мрежама карактеришу се неформалним језиком, честом употребом сленга, скраћеница и правописних грешака, што чини задатак додатно изазовним и релевантним за истраживање у области обраде природних језика.

Приликом прикупљања и претпроцесирања података, посебна пажња посвећена је чишћењу текстуалног садржаја. Емотикони су у потпуности избачени из корпуса, јер њихово присуство може унети додатну семантичку нејасноћу. Наиме, исти емотикон (нпр. палчеви горе) може се појавити и у коментарима подршке протестима и у ироничним коментарима противника, чиме се губи разликовна моћ симбола. Уколико би се емотикони задржали, модел би могао да их погрешно интерпретира као снажан сигнал припадности одређеној класи, што би нарушило поузданост класификације. Избацивањем емотикона, модел се ослања искључиво на лингвистичке маркере, чиме се повећава робусност и интерпретабилност добијених резултата.

1.1. Категорије политичких ставова у скупу података

Скуп података обухвата коментаре који су класификовани у три категорије политичких ставова према односу према студентским протестима и ширим политичким контекстом:

- **Против власти / Подршка протестима** – коментари који изражавају критички став према власти и подршку студентским протестима. Карактерише их лексика подршке („подржавам“, „браво студенти“, „истина“, „правда“, „смењивање“), позитивна емотивна обојеност према протестима, честа критика институција и позивање на транспарентност и одговорност.
- **За власт / Противљење протестима** – коментари који изражавају подршку властима и противљење студентским протестима. Карактерише их лексика

противљења („наплаћени протести“, „студенти су марионете“, „ред и закон“, „одржавање стабилности“), негативна емотивна обојеност према протестима и честа афирмација државних институција и тренутног руководства.

- **Неутрални / Информативни** – коментари који износе чињенице, преносе информације или постављају питања без израженог става. Карактерише их објективан тон, неутрална лексика, често позивање на изворе или пренос информација са других платформи, без експлицитног заузимања стране.

Избегли смо издвајање посебне категорије за саркастичне и ироничне коментаре, као и за оне са амбивалентним или подељеним ставом. Разлог за ову одлуку лежи у чињеници да су саркастични коментари по својој природи дубоко двосмислени – често изражавају став супротан од онога што се буквално каже, што их чини изузетно тешким за аутоматску класификацију. Исти коментар могао би бити протумачен и као подршка и као противљење, у зависности од контекста и читаачеве перцепције. Пошто циљ овог рада није моделирање нијанси ироније, већ препознавање експлицитних политичких ставова, овакве коментаре смо искључили из корпуса. Слична логика примењена је и на коментаре са изразито подељеним ставом, који би додатно компликовали трокласни задатак и увели субјективност у процес анотације.

1.2. Циљ пројекта

Главни циљеви овог пројекта су имплементација, анализа и поређење различитих рачунарских решења која на основу текста једног коментара имају задатак да предвиде политички став који коментар изражава. Поред саме предикције, важан аспект рада односи се на испитивање лингвистичких и стилских одлика које највише доприносе ефикасном разликовању и диференцијацији обухваћених категорија. Истраживање је структурирано кроз неколико кључних фаза, почевши од прикупљања сирових података, преко детаљне анотације, па све до напредног моделовања и евалуације добијених резултата.


2. Прикупљање података

У овом поглављу описан је целокупан процес формирања корпуса — од прикупљања сирових коментара са друштвених мрежа, преко чишћења и стандардизације, до ручне анотације и коначне експлоративне анализе прикупљеног материјала.

2.1. Прикупљање сирових података са друштвених мрежа

Полазну грађу за ово истраживање чинили су јавно доступни коментари са четири друштвене мреже: Instagram, X, YouTube и Facebook. Одабир ових платформи није случајан — оне представљају најпосећеније канале за расправу о друштвено-политичким темама у српском јавном простору, са значајно различитим демографским профилима корисника и обрасцима комуникације.

Прикупљање је вршено претраживањем објава које се односе на студентске протесте у периоду 2024–2026. године, након чега су екстраховани сви коментари испод тих објава. Укупан број сирових коментара износио је 10.870, док је након чишћења задржано 8.912 коментара.



Слика 2.1 Прикупљени коментари по платформи

Као што се види на Слици 2.1, Instagram је најзаступљенија платформа у сировом корпусу са 6.605 коментара, док су остале платформе подједнако заступљене са око 1.200–1.600 коментара.

2.2. Чишћење и стандардизација корпуса

Сирови коментари са друштвених мрежа карактеришу се различитим облицима неформалности који би значајно отежали рад класификационих модела. Будући да су текстови са друштвених мрежа кратки, неформални и често садрже симболе без лексичког садржаја, чишћење је рађено у два нивоа:

- (1) припрема сировог корпуса пре анотације
- (2) претпроцесирање за класичне *baseline* моделе.

2.2.1. Припрема сировог корпуса

Сви експорти чувају се у UTF-8 формату. Празни коментари (који садрже само белине) одбацују се одмах.

Емотикони и сродни графички симболи уклањају се регуларним изразом, након чега се узастопне белине сабијају у један размак. Овај корак је спроведен из два разлога. Прво, емотикони могу унети семантичку двосмисленост — исти симбол (нпр. палчеви горе) може пратити и коментаре подршке протестима и оне са саркастичном намером. Њихово задржавање уносило би буку у податке и довело до погрешног повезивања са класама. Друго, циљ је да у анотацију не уђу примери без језичког садржаја, јер се став не може поуздано одредити из самог емотикона. Коментари који након овог корака немају преостали текст (само емотикони, само симболи) одбацују се.

Правопис, ћирилица/латиница и садржај коментара нису „исправљани“ — текст остаје онакав какав је корисник написао, како би модел видео стварну употребу језика на мрежама.

2.2.2. Анотациони скуп

Из очишћеног корпуса ручно је издвојен подскуп за обележавање. Приликом уписа ознаке текст се не нормализује додатно — остаје оригинални коментар, уз URL и класу — како се не би изгубио сигнал кратких и мешовитих записа.

2.2.3. Претпроцесирање за *baseline* моделе

За логистичку регресију, линеарни SVM и наивни Бајесов класификатор текст се претвара у вектор одлика. Ово није део чишћења корпуса за анотацију, већ експериментални фактори репрезентације, који су равноправно испитани:

- токенизација регуларним изразом (Unicode речи);
- lowercasing (укључен / искључен);
- стемовање — једноставно скидање честих српских наставака;
- лематизација — пакет *simplemma*, језик *sr*; ако лема није доступна, остаје токен малим словима;
- пондерисање: TF, IDF и TF-IDF (n-грами 1–2, min_df=2, max_df=0.95).

2.2.4. Енкодерски модели

BERTић и mBERT користе сопствени подречни токенизатор. Додатно ручно чишћење (стемовање/лематизација) се на њих не примењује, јер би нарушило репрезентацију коју модел већ учи из сировог текста.

2.3. Анотација коментара


Пошто су коментари сакупљени без информације о политичком ставу, било је неопходно спровести ручну анотацију. Процес је подразумевао класификовање сваког коментара у једну од три категорије:

- **PROTIV-VLASTI** – коментари који подржавају студентске протесте и критикују институције. Карактеристична лексика: *подржавам, правда, корупција, смењивање, транспарентност*.
- **ZA-VLAST** – коментари који подржавају тренутну власт и доводе у питање легитимитет протеста. Карактеристична лексика: *ред, закон, стабилност, марионете, наша држава*.
- **NEUTRAL** – коментари без израженог става, који преносе информације или постављају питања. Карактеристична лексика: *људи, народ, бити, треба, како*.

Анотација је спроведена у неколико рунди. Прва фаза подразумевала је заједничко означавање мањег узорка како би се чланови тима усагласили око критеријума, након чега је уследила самостална анотација преосталог корпуса.


2.4. Експлоративна анализа података

Након завршене анотације, финални корпус броји **2.874 коментара**. Слика 2.2. приказује расподелу по класама.



Слика 2.2. Расподела класа у анотираном скупу


Најзаступљенија је класа PROTIV-VLASTI са 1.168 коментара (40,6%), следи ZA-VLAST са 1.038 (36,1%), док су неутрални коментари најређи — 668 (23,2%), што је приказано на Слици 2.3. Однос највеће и најмање класе износи 1,75, што представља умерену неуравнотеженост. Због тога ће се приликом евалуације користити *макро F1 мера*, која подједнако вреднује перформансе на свим класама.




Слика 2.3. Број анотираних коментара по класи

2.4.1. Расподела по платформама

Анализирајући расподелу по платформама (Слика 2.4), уочава се релативно уравнотежен узорак — свака платформа доприноси са приближно 690–780 коментара. Facebook је најзаступљенији (783), следе YouTube (702), Instagram (694) и X (690).



Слика 2.4. Број аотираних коментара по платформи и класи



Слика 2.5 Удео класа унутар сваке платформе

Међутим, када се погледа удео класа унутар сваке платформе (Слика 2.5), долазимо до занимљивих увида. Facebook и X имају већи удео коментара против власти (49% односно 38%), док Instagram предњачи по подршци власти (41%). YouTube се издваја по највећем уделу неутралних коментара (26%). Овакве разлике могу се објаснити демографским и културолошким специфичностима корисника појединих платформи, али и начином на који се на њима граде расправе.


2.4.2. Дужина коментара

Статистика дужине коментара (мерена бројем речи), приказана у Табели 2.1, открива одређене разлике међу класама:


Табела 2.1 – Статистика дужине коментара

Класа	Број	Просек	Медијана	Std	p90	Макс.
NEUTRAL	668	14,65	9,0	21,28	27,3	222
ZA-VLAST	1038	16,34	14,0	14,52	29,0	128
PROTIV-VLASTI	1168	15,82	12,0	17,70	31,0	214

Коментари који подржавају власт су у просеку најдужи (медијана 14 речи), док су неутрални најкраћи (медијана 9 речи). Ово је интуитивно очекивано — изражавање става често захтева више речи него пуко преношење информације. Највећу варијабилност показују неутрални коментари, што указује да се међу њима налазе и веома опширни, али и изразито сажети примери. На Слици 2.6 може се видети дистрибуција дужине коментара по класи.



Слика 2.6 Дистрибуција дужине коментара по класи




Слика 2.7 Дужина коментара по платформи

Посматрано по платформама, најдужи коментари потичу са *Instagram*-а и *Facebook*-а, где корисници чешће остављају опширније изразе. На X-у су коментари очекивано краћи, што је последица ограничења дужине твитова. Ово се може видети на Слици 2.7.

2.4.3. Најчешће речи — семантички отисак класа

Анализа најфреквентнијих речи по класама (Слика 2.8) потврђује да су класе семантички добро одвојене. Код неутралних коментара доминирају опште речи попут *људи*, *народ*, *било*, *треба*, без јаке емотивне обојености. Код присталица власти истичу се речи *наша*, *држава*, *Србија*, што указује на патриотски дискурс. Код противника власти доминирају речи *корупција*, *правда*, *мора* — што говори о критичком тону и захтевима за променама.



Слика 2.8 Најзаступљенији токени по класи

Изнесени подаци указују на то да прикупљени коментари садрже јасне и систематске језичке обрасце својствене свакој од три класе, што представља добру полазну основу за даље моделовање. Наредна фаза рада бавиће се управо питањем у којој мери се ови уочени обрасци могу искористити за аутоматску класификацију политичких ставова, као и који типови модела најбоље успевају да их препознају.

3. Обучавање и евалуација модела

У трећој фази истраживања разматрају се различити приступи класификацији става (*stance classification*) коментара који се односе на студентске протесте у Србији. Циљ ове фазе је да се успостави репрезентативна *baseline* вредност применом класичних алгоритама машинског учења, а затим испита у којој мери *Transformer* модели могу да унапреде резултате. Експерименти су подељени на два приступа: класичне моделе машинског учења и енкодер *Transformer* моделе. Посебна пажња посвећена је утицају начина представљања текста и претпроцесирања, као и фер поређењу модела применом стратификоване унакрсне валидације. Тренирање и евалуација модела извршени су локално на рачунару опремљеном графичком картицом *NVIDIA GeForce RTX 3090* уз коришћење *CUDA* подршке за убрзање израчунавања на графичком процесору.

3.1. *Baseline* модели

Циљ *baseline* експеримената је успостављање референтне вредности за задатак класификације става, која ће у наставку бити коришћена за процену успешности сложенијих *Transformer* приступа. Класификација се врши у три класе: *NEUTRAL*, *ZA-VLAST* и *PROTIV-VLASTI*. Коришћен је скуп *dataset_all.txt*, који садржи укупно 2874 примера. Расподела примера по класама није равномерна: класа *NEUTRAL* садржи 668 примера (23,2%), *ZA-VLAST* 1038 примера (36,1%), док *PROTIV-VLASTI* садржи 1168 примера (40,6%). Оваква неуравнотеженост је посебно значајна приликом избора евалуационе метрике, јер укупна тачност може дати превише оптимистичну слику успешности модела уколико модел боље препознаје бројније класе.

Као *baseline* модели коришћени су *Multinomial Naive Bayes (NB)*, *Logistic Regression (LR)* и *Linear Support Vector Machine (SVM)*. Сва три модела представљају стандардне приступе за класификацију текстуалних података и омогућавају успостављање релативно једноставне, али релевантне референтне тачке за касније поређење са *Transformer* моделима. *Logistic Regression* и *Linear SVM* су погодни за рад са високодимензионалним и ретким текстуалним репрезентацијама, док *Multinomial Naive Bayes* експлицитно моделује расподелу термина по класама и често се користи као ефикасан *baseline* у задацима текстуалне класификације.

3.1.1. Претпроцесирање и репрезентација текста

За разлику од једног унапред дефинисаног *baseline* модела, у експериментима је испитан и утицај различитих начина представљања и претпроцесирања текста. Разматране су три врсте пондерисања термина: **TF**, **IDF** и **TF-IDF**. На тај начин је омогућено да се утврди да ли је **TF-IDF**, који се често користи као стандардна репрезентација у текстуалној класификацији, заиста најпогоднији избор за посматрани скуп података.

Поред пондерисања, испитиван је и утицај **lowercasing-a**, као и нормализације токена. За нормализацију су разматране три варијанте: без нормализације (*none*), *stemming*

(*stem*) и *lemmatization* (*lemma*). Комбиновањем ових фактора добијено је укупно 54 конфигурације, односно $3*3*2*3$. На овај начин експеримент није усмерен само на избор најбољег класификатора, већ и на утврђивање утицаја различитих начина припреме текстуалних података.

Резултати показују да је **stemming** имао најбољи просечан резултат међу разматраним стратегијама нормализације. Просечан *macro-F1* за *stem* износио је 0,5379, док су *lemma* и *none* остварили 0,5125 и 0,5004. Овај резултат указује да свођење сродних облика речи на заједничку основу може бити корисно за кратке коментаре на српском, односно ВСМС језичком простору. Додатно, *lowercasing* је у просеку такође имао позитиван ефекат: конфигурације са укљученим *lowercasing*-ом оствариле су просечан *macro-F1* од 0,5210, у поређењу са 0,5129 код конфигурација без њега.

Занимљив резултат добијен је код пондерисања термина. Најбољи просечан резултат остварен је употребом **TF** репрезентације (0,5217), затим **IDF** (0,5158), док је **TF-IDF** имао најнижи просечан *macro-F1* од 0,5132. Ово показује да **TF-IDF** није нужно оптималан избор за сваки задатак текстуалне класификације. Код кратких коментара, сама учесталост термина може садржати корисну информацију о ставу, док додатно потискивање често присутних речи кроз **IDF** пондерисање не мора нужно да доведе до побољшања резултата.

3.1.2. Евалуација

За евалуацију *baseline* модела коришћена је **угнежђена стратификована унакрсна валидација** (*nested stratified cross-validation*). Спољашњи део валидације састојао се од 10 *fold*-ова, док су унутрашњи *fold*-ови коришћени за избор хиперпараметара. Овакав приступ омогућава одвајање процеса избора хиперпараметара од коначне процене модела и тиме смањује ризик од оптимистичке процене перформанси услед прилагођавања модела евалуационим подацима.

За *Logistic Regression* и *Linear SVM* разматране су вредности параметра $C \in \{0.1, 1.0, 10.0\}$, док су за *Multinomial Naive Bayes* испитиване вредности $\alpha \in \{10.1, 0.5, 1.0\}$. Приликом евалуације пријављени су *accuracy*, *macro-F1*, *weighted-F1*, као и *F1* резултат за сваку појединачну класу. Као главна метрика изабран је *macro-F1*, јер равноправно третира све три класе и самим тим пружа прикладнију меру перформанси на неуравнотеженом скупу.


3.1.3. Резултати

Најбољу конфигурацију остварила је **Logistic Regression** са **TF** пондерисањем, укљученим *lowercasing*-ом и *stemming*-ом, уз вредност $C=1.0$. Ова конфигурација је остварила **macro-F1** од **0,5532**, *accuracy* од 0,5825 и *weighted-F1* од 0,5791. Резултати су приказани у Табели 3.1.

Табела 3.1 Резултати најбоље *baseline* конфигурације по класи

Метрика	Резултат
Macro-F1	0,5532
Accuracy	0,5825
Weighted-F1	0,5791
F1 — NEUTRAL	0,3806
F1 — ZA-VLAST	0,6451
F1 — PROTIV-VLASTI	0,6340


Резултати по класама показују значајну разлику у успешности класификације. Најбољи резултат добијен је за класу ZA-VLAST, са F1 резултатом 0,6451, док је класа PROTIV-VLASTI остварила F1 од 0,6340. Најслабији резултат добијен је за класу NEUTRAL, чији F1 износи свега 0,3806. Ово указује да је препознавање неутралних коментара главно ограничење *baseline* приступа.



Слика 3.1 Макро-F1 за 15 најбољих конфигурација


Слика 3.1 приказује рангирање најбољих конфигурација по макро-F1. Види се да врх листе доминирају варијанте са *stem* нормализацијом и да су LR и SVM близу један другом, док NB нешто заостаје на самом врху, али остаје конкурентан.

Најслабија испитана конфигурација била је **SVM + IDF + без lowercasing-a + none**, са макро-F1 резултатом од 0,4646. Разлика између најбоље и најслабије конфигурације износила је приближно 0,089 макро-F1, што показује да избор претпроцесирања и текстуалне репрезентације има значајан утицај на резултат, чак и када се користи исти тип класификатора.



Слика 3.2 Расподела макро-F1 по моделу за све конфигурације


Слика 3.2 показује расподелу макро-F1 преко свих конфигурација сваког модела. LR има и најбољи максимум и стабилан просек; NB је близак по просеку, док SVM има нешто нижи просек али још увек јак најбољи резултат (0.5475).



Слика 3.3 Просечан макро-F1 по пондерисању


Слика 3.3 приказује просечан макро-F1 по пондерисању: TF са 0.5217 благо надмашује IDF са 0.5158 и TF-IDF са 0.5132. Дакле, на овом скупу кратких коментара TF-IDF није аутоматски најбољи избор.

Слика 3.4 додатно укршта модел и пондерисање (најбољи macro-F1 у свакој ћелији). *Heatmap* потврђује да комбинације LR/SVM са TF или IDF дају најјаче ћелије, док TF-IDF није доминантан ни за један модел.




Слика 3.4 *Heatmap* најбољи макро-F1 за типове пондерисања и сва 3 модела

Слика 3.5 показује да је stem (просек 0.5379) јасно бољи од lemma (0.5125) и none (0.5004). Стемовање спаја морфолошке варијанте у кратким BCMS коментарима и представља најважнији фактор претпроцесирања у овом експерименту.




Слика 3.5 Просечан макро-F1 по нормализацији токена




Слика 3.6 Просечан макро-F1 за *lowercasing*

Слика 3.6 показује благу предност укљученог lowercasing-a: 0.5210 наспрам 0.5129. Ефекат постоји, али је мањи од ефекта стемовања.



Слика 3.7 Најбоља конфигурација – F1 по класи

Слика 3.7 приказује F1 по класама за глобалног победника (LR + TF + stem). Класа NEUTRAL је значајно слабија (≈ 0.38) од ZA-VLAST и PROTIV-VLASTI (≈ 0.63 – 0.65), што је очекивано јер су неутрални коментари мање лексички „обојени“ и мање заступљени.



Слика 3.8 Упоредна анализа F1 мере по класи за најбоље конфигурације сва 3 модела

Слика 3.8 упоређује најбољу конфигурацију сваког модела по класама. Сва три модела имају исти образац: најслабији NEUTRAL, јачи ZA-VLAST и PROTIV-VLASTI. Разлике међу моделима су мале у односу на јаз између NEUTRAL и осталих класа.

3.1.4. Дискусија

Baseline експерименти показују да једноставни модели засновани на статистичким карактеристикама текста могу да обезбеде релативно солидну основу за задатак класификације става. Од 54 испитане конфигурације (LR, SVM и NB $\times$ TF/IDF/TF-IDF $\times$ lowercasing $\times$ none/stem/lemma), најбољи резултат остварила је логистичка регресија са комбинацијом TF + stemming (macro-F1 = 0,5532, accuracy = 0,5825). Близу су и најбољи SVM (0,5475) и NB (0,5377), што сугерише да на овом скупу избор репрезентације и претпроцесирања често има подједнак, ако не и већи утицај од самог избора класификатора.

Посебно је важно да није оправдано претпоставити да ће TF-IDF нужно бити најбоља репрезентација. У посматраном скупу TF је имао најбољи просечан macro-F1 (0,5217), испред IDF (0,5158) и TF-IDF (0,5132). То се може повезати са специфичностима кратких коментара на друштвеним мрежама: у таквим текстовима учесталост појединих речи и израза често директније указује на став аутора, док IDF/TF-IDF казна за „честе“ термине не мора увек да помогне када је контекст већ ограничен.

Још израженији је утицај нормализације токена. Стемовање јасно надмашује lemma и варијанту без нормализације (просечан macro-F1: stem 0,5379; lemma 0,5125; none 0,5004). Позитиван утицај stemming-а указује на значај језички прилагођеног претпроцесирања: код кратких коментара различити морфолошки облици исте речи могу носити исти сигнал класе, па њихово свођење на заједничку основу повећава ефективну количину информација доступну класификатору. Lowercasing даје благу додатну предност, али његов ефекат је мањи од ефекта стемовања.

Са друге стране, веома низак F1 за класу NEUTRAL ($\approx 0,38$ код победничке конфигурације, наспрам $\approx 0,63$ – $0,65$ за ZA-VLAST и PROTIV-VLASTI) показује да класични модели имају потешкоћа у раздвајању неутралних коментара од оних који имплицитно или експлицитно изражавају став. Овај проблем је посебно изражен код кратких текстова, где је контекст ограничен, а став често није директно исказан. Исти образац се понавља и код најбољих конфигурација свих три модела, што сугерише да је реч о ограничењу саме *bag-of-words* репрезентације, а не само о слабости једног класификатора.

Распон између најбоље и најслабије конфигурације ($\approx 0,089$ поена macro-F1) даље потврђује да су избори у претпроцесирању практично битни: лоша комбинација фактора може значајно ослабити иначе употребљив модел. Истовремено, чињеница да врх листе чине конфигурације са stem-ом говори да је тај фактор најстабилнији „добитник“ експеримента.

Укупно, *baseline* резултат од macro-F1 = 0,5532 представља референтну (доњу) границу за наредне експерименте. У наставку се испитује да ли *Transformer* енкодери (BERTić и mBERT), који могу да искористе контекстуалне односе између речи, могу да превазиђу ограничења класич

3.2. Енкодер

Циљ енкодер приступа је испитивање могућности *Transformer* модела да науче контекстуалне представе кратких коментара и на тај начин унапреде класификацију става у односу на *baseline* моделе (најбољи macro-F1 = 0,5532). За разлику од класичних приступа, код којих се текст представља независним статистичким карактеристикама, *Transformer* модел током *fine-tuning*-а учи репрезентацију текста која узима у обзир контекст и односе између токена. Циљ је двострук: упоредити монолингвални BCMS модел са мултилингвалним BERT-ом и измерити добитак у односу на класични ML.

3.2.1. Модели

У експерименту су упоређена два *Transformer* модела: **BERTić**, односно *classla/bcms-bertic*, и **mBERT**, односно *bert-base-multilingual-cased*. BERTić представља модел прилагођен BCMS језичком простору, док је mBERT мултилингвални модел обучен

на већем броју језика. Поређењем ова два приступа испитује се да ли језички специфични модел, обучен за језички простор који обухвата српски језик, пружа предност у односу на општији мултилингвални модел.

Хипотеза: BERTiћ боље моделује локални идиом; mBERT нуди ширу мултилингвалну репрезентацију, али мање специјализације за српски/BCMS.

3.2.2. Поставка и хиперпараметри

Оба модела су обучавана под истим условима како би њихово поређење било што коректније. За *fine-tuning* је коришћен ***Hugging Face Trainer***. Коришћени су и *weight decay* од 0,01 и *warmup ratio* од 0,1. Обука се извршава на CUDA уколико је доступна. У Табели 3.2 дати су коришћени хиперпараметри. После CV-а сваки модел се још једном тренира на целом скупу и чува за инференцу.

Табела 3.2 Хиперпараметри енкодер модела


Хиперпараметар	Вредност
Епохе	4
Batch size	8
Learning rate	2×10^{-5}
Max length	128
Weight decay	0,01
Warmup ratio	0,1
Евалуација	Стратификована 10-fold CV
Главна метрика	Macro-F1

Евалуација енкодер модела врши се применом **стратификоване 10-fold cross-validation**. Стратификација обезбеђује да расподела три класе буде што сличнија у различитим *fold*-овима, што је посебно важно због неуравнотежености скупа. За разлику од *baseline* приступа, где је *nested CV* коришћен за избор хиперпараметара, овде је циљ да се процени стабилност и генерализациона способност *Transformer* модела под фиксним условима обуке.

Након завршетка *cross-validation* експеримената, модели се поново обучавају на **целокупном скупу од 2874 примера**. Овај корак омогућава да се за финалну примену искористе сви расположиви означени подаци, након што је евалуација већ спроведена. BERTiћ и mBERT модели се чувају одвојено, како би се омогућили независан инференс и директно поређење њихових предвиђања.

3.2.3. Резултати


Победник је **BERTiћ**. У односу на mBERT предност износи 0,0665 поена macro-F1; у односу на најбољи *baseline* (LR + TF + stem) предност је око 9,4 процентна поена. Оба *Transformer* модела надмашују *baseline*, али је добитак BERTiћ-а значајно већи.



Слика 3.9 — Поређење метрика BERTiћ vs mBERT

На Слици 3.9 се види да BERTić доминира по све три метрике. Разлика није ограничена само на макро-F1: виши су и ассигасу и weighted-F1, што значи да побољшање није последица само једне класе већ укупно бољег понашања модела.

Слика 3.10 потврђује исти редослед: BERTić (4 епохе) је изнад mBERT-а (4 епохе). Пошто су хиперпараметри и протокол евалуације идентични, разлика се може приписати самом претренираном моделу (монолингвални BCMS наспрам мултилингвалног BERT-а).




Слика 3.10 — Рангирање модела по макро-F1

У Табели 3.3 могу се видети перформансе по класама. BERTić побољшава све три класе у односу на *baseline*. Највећи квалитативни помак је код класе NEUTRAL (са 0,38 на 0,51), која је у *baseline* експериментима била уско грло. Ипак, и код енкодера NEUTRAL остаје најслабија класа, док су ZA-VLAST и PROTIV-VLASTI знатно јаче.

Табела 3.3 Перформансе по класама

Модел	F1 NEUTRAL	F1 ZA-VLAST	F1 PROTIV-VLASTI
BERTić	0,5137	0,7371	0,6904
mBERT	0,4498	0,6689	0,6229
<i>Baseline</i> (најбољи)	0,3806	0,6451	0,6340



Слика 3.11 — F1 по класи за оба модела

Графикон на Слици 3.11 показује исти образац код оба модела: најнижи F1 за NEUTRAL, затим PROTIV-VLASTI, па највиши за ZA-VLAST. BERTić је бољи у свакој колони, што указује на систематску, а не случајну предност. Побољшање код NEUTRAL сугерише да контекстуалне репрезентације помажу тамо где класични bag-of-words модели губе сигнал у кратким и двосмисленим коментарима. За детаљнији увид, у Табели 3.4 испод су *precision* и *recall*.

Табела 3.4 Перформансе енкодер модела по класама

Модел	Класа	Precision	Recall	F1
BERTić	NEUTRAL	0,5386	0,4910	0,5137
BERTić	ZA-VLAST	0,7354	0,7389	0,7371
BERTić	PROTIV-VLASTI	0,6751	0,7063	0,6904

Модел	Класа	Precision	Recall	F1
mBERT	NEUTRAL	0,4649	0,4356	0,4498
mBERT	ZA-VLAST	0,6683	0,6696	0,6689
mBERT	PROTIV-VLASTI	0,6126	0,6336	0,6229


Код NEUTRAL оба модела имају нижи recall од precision-a (посебно BERTiћ: recall 0,49), што значи да се део неутралних коментара и даље класификује као став „за“ или „против“. Код ZA-VLAST су precision и recall избалансиранији, што објашњава највиши F1 управо за ту класу.

Анализа појединачних fold-ова (табела 3.5) показује да је BERTiћ стабилно бољи од mBERT-a (просечан fold macro-F1 $0,647 \pm 0,029$ наспрам $0,581 \pm 0,023$), те да предност није последица једне повољне поделе скупа.

Табела 3.5 Стабилност macro-F1 по 10 fold-овима за BERTiћ и mBERT


Модел	mean fold macro-F1	std	min	max
BERTiћ	0,6474	0,0290	0,5965	0,6970
mBERT	0,5805	0,0230	0,5447	0,6161

Слика 3.12 показује да BERTiћ има виши ниво перформанси на скоро свим fold-овима, док mBERT остаје у нижем опсегу. Стандардне девијације су релативно мале ($\approx 0,02$ – $0,03$), што говори да резултати нису последица једне „срећне“ поделе скупа. BERTiћ има нешто већи распон (min–max), али и знатно виши просек и максимум; mBERT је нешто компактнији, али системски слабији. Стога је закључак BERTiћ > mBERT поуздан у оквиру 10-fold протокола.




Слика 3.12 — Расподела macro-F1 по 10 fold-ова

Матрице конфузије, на Сликама 3.13 и 3.14 приказују где модели праве грешке: редови су стварне класе, колоне предвиђене класе.



Слика 3.13 Матрица конуфзије за BERTić

Код BERTiĆ-a највише тачних предикција је на дијагонали: 328 за NEUTRAL, 767 за ZA-VLAST и 825 за PROTIV-VLASTI. Грешке код NEUTRAL најчешће одлазе у PROTIV-VLASTI (216) и ZA-VLAST (124), што потврђује да модел често „повуче“ неутрални коментар ка једном од два поларизована става. Обрнуто, део коментара PROTIV-VLASTI и ZA-VLAST завршава као NEUTRAL (191 односно 90), што указује на двосмерну конфузију око неутралности.



Слика 3.14 Матрица конуфзије за mBERT

Код mBERT-a образац грешака је сличан, али су дијагоналне вредности ниже (291 / 695 / 740). Посебно је израженије мешање NEUTRAL ↔ PROTIV VLASTI и NEUTRAL ↔ ZA VLAST. Поређењем две матрице види се да BERTiĆ доследно боље одваја све три класе, уз исти тип најчешћих грешака — што сугерише да проблем NEUTRAL класе није потпуно решен ни Transformer архитектуром, али јесте значајно ублажен у односу на baseline и у односу на mBERT.

3.2.4. Дискусија

Fine-tuning Transformer модела доноси јасан добитак у односу на *baseline*: BERTić (macro-F1 = 0,647) надмашује најбољу логистичку регресију за око 0,094, док је добитак mBERT-а умерен (+0,027). Пошто су хиперпараметри и протокол евалуације били идентични, предност BERTić-а над mBERT-ом (~0,067) поткрепљује хипотезу да монолингвални BCMS модел боље одговара овом задатку од општег мултилингвалног BERT-а.

Најважнији квалитативни помак је код класе NEUTRAL ($F1 \approx 0,38 \rightarrow 0,51$ код BERTić-а), што указује да контекстуалне репрезентације помажу тамо где n-gram модели губе сигнал. Ипак, NEUTRAL остаје најслабија класа, уз типично мешање са поларизованим ставовима — проблем дакле није потпуно решен самим преласком на Transformer. Уз стабилну предност по fold-овима, за примену је оправдан избор BERTić-а као главног енкодерског модела.

4. Закључак

У овом раду реализован је целовит ток за класификацију става јавних коментара о студентским протестима у Србији, кроз три фазе: прикупљање података, анотацију и обучавање модела.

У Фази 1 прикупљени су коментари са четири платформе (*Instagram*, *X*, *YouTube*, *Facebook*). Од око 10 870 сирових текстова, након чишћења задржано је око 8 900, а у финални анотирани скуп ушло је 2874 примера. Тиме је направљен употребљив корпус за учење, уз очекивани губитак обима због квалитета и ручне селекције.

У Фази 2 коментари су обележени у три класе: NEUTRAL, ZA-VLAST и PROTIV-VLASTI. Скуп је неуравнотежен (најмање неутралних примера), због чега је у евалуацији као главна метрика коришћен macro-F1.

У Фази 3 упоређени су класични и *Transformer* приступи. Најбољи *baseline* модел (логистичка регресија + TF + stemming) достиже macro-F1 = 0,553. *Fine-tuning* енкодера показује јасан напредак: BERTiћ достиже macro-F1 = 0,647, испред mBERT-a (0,581) и baseline-a. Монолингвални BCMS модел показао се бољим од мултилингвалног, а највећи квалитативни добитак је код класе NEUTRAL, која ипак остаје најтежа.

Главни допринос рада је практичан *pipeline* — од прикупљања и анотације до упоредиве евалуације модела — као и емпиријски налаз да *Transformer fine-tuning*, посебно BERTiћ, значајно надмашује класичне моделе на овом задатку. За даљи рад највећи потенцијал лежи у бољем третману неутралних коментара, проширењу корпуса и поређењу са декодерским (prompting) приступима.